

Contexto

Según la Organización Mundial de la Salud (OMS), el ictus es la segunda causa principal de muerte a nivel mundial, responsable de aproximadamente el 11% del total de muertes.

Datos

Este conjunto de datos se utiliza para predecir la probabilidad de que un paciente sufra un ictus según parámetros como el sexo, la edad, diversas enfermedades y el tabaquismo. Se cuenta con 5110 filas, y cada una proporciona información relevante sobre el paciente.

Los datos se encuentran en un csv descargado de [Kaggle](#).

La información con la que se cuenta es la siguiente:

id: identificador único.

gender: género del paciente.

age: edad del paciente.

hypertension: 0 si el paciente no tiene hipertensión, 1 si la tiene.

heart_disease: 0 si el paciente no tiene alguna enfermedad cardíaca, 1 si tiene.

ever_married: "Yes" o "No", si ha estado casado.

work_type: Tipo de trabajo.

Residence_type: Zona de residencia. "Rural" o "Urbana".

avg_glucose_level: Promedio de glucosa en sangre.

bmi: Índice de masa corporal.

smoking_status: Condición de fumador.

stroke: 1 si el paciente tuvo un ictus, 0 si no.


Análisis exploratorio de los datos (EDA)

En primer lugar se revisó la presencia de nulos, y se detectó casi un 4% de datos faltantes en la variable "bmi".

Luego se observó la distribución y los valores de cada una de las variables.

Género



Se observó que poseía un solo paciente que contenía "Other" como género, por lo cual se procedió a eliminarlo para no incorporar datos dudosos.





Variables binarias ("Yes"/"No" - 1/0)

Respecto a la hipertensión y la presencia de enfermedades cardíacas, se observa poca representación de casos positivos (entre el 5% y el 10%). En cuanto a la representación de cada caso por género, se observa bastante equilibrado.



Hypertension



Heart disease





Ever married





Variables categóricas

Respecto a la hipertensión y la presencia de enfermedades cardíacas, se observa poca representación de casos positivos (entre el 5% y el 10%). En cuanto a la representación de cada caso por género, se observa bastante equilibrado.



Work type



Residence type





Smoking status



Variables numéricas

El rango de edades es amplio, abarcando desde bebés hasta adultos mayores, y todos los rangos están bastante representados.

Age





En cuanto al BMI, tiene una distribución sesgada a la derecha (asimétrica positiva). Los indicadores esperados en adultos (más de 20 años) son:


- Bajo peso: < 18.5
- Normal: $18.5 - 24.9$
- Sobrepeso: $25 - 29.9$
- Obesidad: ≥ 30

En nuestro conjunto de datos tenemos casi la mitad de los adultos con obesidad, y solo un 20% con BMI "normal".

Bmi



Clasificación según BMI en adultos




En cuanto a los niveles de glucosa, también tenemos una distribución sesgada a la derecha, aunque con una pequeña subpoblación con valores altos. Los indicadores, suponiendo que son valores en ayunas, son:


- Normal: < 100
- Prediabetes: $100 - 125$
- Diabetes: ≥ 126

En nuestro conjunto de datos tenemos más de la mitad de los adultos con niveles normales de glucosa.

Avg glucose level




Clasificación según niveles de glucosa en adultos




Outliers

Después de ver la distribución de los BMI, se consideró necesario eliminar los outliers extremadamente altos. Se utilizó el método de los rangos intercuartílicos, y se pudo observar también que los valores a eliminar eran negativos para “stroke”, por lo que no estamos eliminando datos de gran interés.

Distribución BMI



Distribución BMI luego de eliminar outliers




Datos faltantes

Debido al tipo de distribución que posee la variable y considerar los valores de su promedio y moda, se consideró más confiable completar los datos faltantes con la moda correspondiente a cada género.

BMI Media: 28.82, Moda: 28.7				
	media	moda	max	min
gender				
Female	29.011753	23.4	61.6	10.3
Male	28.542451	26.7	59.7	11.5

Distribución BMI





Correlaciones

Previo a analizar la correlación entre las variables, se reemplazaron los datos de "gender", "ever_married", y "Residence_type" por 0 y 1 para convertirlas en variables numéricas.


La correlación se analizó sobre todas las variables numéricas, excepto la variable objetivo ("stroke"), ya que esta se analizará por separado.

No se observó gran correlación entre variables, excepto por las variables "age" y "ever_married", lo cual es esperable ya que es muy probable que a mayor edad aumente la probabilidad de haberse casado.




Variable objetivo (“Stroke”)


En primer lugar, se observó que la representación de cada caso (positivo y negativo) para la variable objetivo está muy desbalanceado, siendo sólo el 5% de los casos positivos.



En cuanto a su representación para cada caso de las otras variables, se observó una representación equilibrada (consistente con su proporción general). También se puede observar tanto gráficamente como por el índice de correlación, una pequeña tendencia a que aumente la probabilidad de “stroke” positivo a mayor edad.



Representación de Stroke por variable



Modelos predictivos

Para poder desarrollar los modelos, se aplicó dummies a las variables categóricas, y se eliminó la variable "id" ya que no es relevante, quedando nuestro dataset con las siguientes columnas:

- gender
- age
- hypertension
- heart_disease
- ever_married
- Residence_type
- avg_glucose_level
- bmi
- work_type_Govt_job
- work_type_Private
- work_type_Self-employed
- work_type_children
- smoking_status_formerly smoked
- smoking_status_never smoked
- smoking_status_smokes
- stroke

Preparación de los datos


Una vez que se dividieron los datos en X e y se procedió a realizar los ajustes necesarios para poder utilizarlos en nuestros modelos.

- **División en Train y Test**

Se utilizó el 75% de los datos para train y el 25% restante para test.

- **Balanceo**

Debido al gran desbalance de la variable objetivo, se aplicó SMOTENC en el conjunto de train, quedando nuestros datos representados equitativamente.



- **Escalado**


Por último se realizó un escalado de las variables continuas ("age", "avg_glucose_level", y "bmi") utilizando StandardScaler.

Entrenamiento, optimización y evaluación de modelos

Para la evaluación de los modelos, se calculó accuracy, f1, precision y recall, pero se buscó priorizar el recall, ya que dada la naturaleza del caso que se está analizando, se considera mucho más importante predecir la mayor cantidad de positivos verdaderos.


- **Regresión logística**

Para comenzar, se entrenó un modelo básico de regresión logística, obteniendo un recall del 50%.




- **Vecinos cercanos (KNN)**

Luego se probó un modelo clasificador de vecinos cercanos con un número de vecinos igual a 50. La optimización de este parámetro se realizó buscando el mejor recall pero sin caer en un overfitting y equilibrando las otras métricas de evaluación). Con este modelo se obtuvo un recall del 70%.





```
KNeighborsClassifier
KNeighborsClassifier(n_neighbors=50)
```




- **Random Forest**

Por último se evaluó un random forest, utilizando una profundidad máxima igual a 3, utilizando el mismo criterio de optimización que KNN. Con este modelo se volvió a obtener un recall del 70%.





También se observó la importancia de las variables para este modelo, y vemos que la más importante es la edad, seguida por ever_married (que ya vimos que está algo correlacionada con la edad). Luego también tienen algo de importancia el nivel de glucosa, el bmi, work_type_children y work_type_Govt_job.



Resumen

Modelo	Accuracy	F1 score	Recall	Precision
Regresión logística	0,79	0,2	0,53	0,12
KNN	0,74	0,21	0,73	0,13
RandomForest	0,7	0,19	0,73	0,11

Conclusión

De los tres modelos evaluados se podría considerar como mejor al modelo KNN, ya que fue el que presentó mejor recall (igual que random forest pero mejora un poco la precisión).

Sin embargo no es un resultado muy bueno, por lo que se podría seguir probando modelos más avanzados, y sobre todo buscar aumentar el tamaño del dataset ya que al estar tan poco representado el grupo positivo es muy difícil mejorar la sensibilidad sin caer en una disminución de la precisión.

Por último también se pudo confirmar que la probabilidad de sufrir un ictus aumenta principalmente con la edad.